



Universidad  
Nacional  
de Córdoba



Facultad de Matemática,  
Astronomía, Física y  
Computación

# Sistema Predictivo de Deserción Universitaria y Perfilado de Estudiantes en Riesgo

Bocco, Noelia - Ruiz, Luciana

7 de agosto de 2026

## 1. Introducción

El presente trabajo documeta el análisis realizado en el notebook [Abandono escolar](#).

El objetivo principal es identificar los factores asociados al abandono, la permanencia y la graduación de estudiantes universitarios mediante técnicas de Machine Learning. Para ello se utilizó un conjunto de datos que contiene información académica, socioeconómica y demográfica de estudiantes matriculados en distintas carreras de grado, entre ellas Agronomía, Diseño, Educación, Periodismo, Administración, Servicios Sociales y Tecnología.

A partir de este conjunto de datos se llevó a cabo un proceso completo de análisis que incluyó etapas de limpieza y preparación de datos, análisis exploratorio, visualización, reducción de dimensionalidad y construcción de modelos predictivos de clasificación multiclase.

## 2. Descripción del Dataset

El dataset contiene 4424 instancias (cada una correspondiente a un estudiante) y 37 variables descriptivas.

Las variables pueden agruparse en las siguientes categorías:

- Datos demográficos del estudiante.
- Información de ingreso a la universidad.
- Variables académicas del primer y segundo semestre.
- Variables económicas y financieras.
- Información familiar.
- Variable objetivo: estado final del estudiante:
  - **Dropout** (abandono)
  - **Enrolled** (continúa estudiando)
  - **Graduate** (graduado)

### 3. Herramientas Utilizadas

El trabajo fue implementado en Python utilizando distintas bibliotecas para el procesamiento de datos, visualización y aprendizaje automático.

- Procesamiento de datos
  - Pandas
  - NumPy
- Visualización de datos
  - Matplotlib
  - Seaborn
- Machine Learning (Scikit-Learn)
  - *Modelos*: Random Forest (RandomForestClassifier), Regresión Logística, K-Nearest Neighbors (KNeighborsClassifier), Árboles de Decisión (DecisionTreeClassifier), Máquinas de Vectores de Soporte (SVC), Naive Bayes (GaussianNB).
  - *Métricas*: Accuracy, Reporte de Clasificación, Matriz de Confusión, ROC AUC y Average Precision
  - *Procesamiento*: train\_test\_split, label\_binarize, GridSearchCV, TSNE.

### 4. Procesamiento de Datos

Las principales tareas realizadas fueron:

- Traducción y normalización de nombres de variables.
- Conversión de variables importadas incorrectamente como texto.
- Verificación de valores faltantes.
- Verificación de registros duplicados.
- Codificación de la variable objetivo.
- Escalado de variables mediante StandardScaler.

Los resultados mostraron que el conjunto de datos no presentaba valores faltantes ni registros duplicados, lo que permitió trabajar sobre una base de datos consistente para el entrenamiento de los modelos.

#### 4.1. Variables

Tenemos 7 variables numéricas reales (float64), 1 de tipo texto (object) que es nuestro objetivo (el target a predecir), y el resto son números enteros (int64).

Es importante destacar que muchas de las variables enteras representan categorías codificadas y no valores numéricos continuos.

En las variables categóricas, como por ejemplo el estado civil o el curso elegido, no tiene sentido interpretar medidas como el promedio. Por esta razón, su análisis se realizó mediante el estudio de frecuencias y distribuciones.

Por otro lado, las variables numéricas reales sí permiten realizar análisis estadísticos descriptivos, ya que aportan información relevante sobre el perfil académico y socioeconómico de los estudiantes.

## 4.2. Distribución del Éxito Académico

La Figura 1 muestra la distribución de la variable objetivo. Se observa que las clases no se encuentran completamente balanceadas.




Figura 1: Distribución de la variable objetivo

La clase con mayor cantidad de observaciones es **Graduate**, seguida por **Dropout**, mientras que **Enrolled** es la menos representada.

Por este motivo, la métrica **Accuracy (Exactitud)** no resulta suficiente para evaluar el desempeño de los modelos. Un modelo podría obtener una buena exactitud simplemente clasificando correctamente las clases mayoritarias, sin identificar adecuadamente a los estudiantes en riesgo de abandono.

Dado que uno de los principales objetivos del trabajo es detectar estudiantes con riesgo de deserción, se decidió priorizar métricas más adecuadas para conjuntos de datos desbalanceados, especialmente **Recall** y **F1-Score** para la clase *Dropout*.

El **Recall** permite medir qué proporción de los estudiantes que realmente abandonan sus estudios es identificada correctamente por el modelo.

Por otro lado, el **F1-Score** combina Precision y Recall en una única medida, permitiendo evaluar el equilibrio entre detectar correctamente los casos de abandono y evitar falsas alarmas.

Por estas razones, la selección del modelo final se basó principalmente en el análisis de Recall y F1-Score para la clase *Dropout*, complementados con la matriz de confusión y el reporte de clasificación.

## 4.3. Interrelación de Variables

Antes de analizar cada variable de manera individual, se construyó un mapa de calor de correlaciones con el objetivo de obtener una visión general de las relaciones existentes entre las variables del conjunto de datos.

Como se observa en la Figura 2, la mayoría de las variables presentan correlaciones débiles, lo que indica una baja dependencia lineal entre ellas. Sin embargo, se identifica un grupo de variables con una fuerte correlación positiva (representada por los tonos morados más oscuros),

correspondiente a los indicadores académicos del primer y segundo semestre, tales como la cantidad de materias matriculadas, aprobadas y las calificaciones obtenidas.




Figura 2: Mapa de calor de correlaciones del dataset.

#### 4.4. ¿Qué factores influyen más en el abandono universitario?

Con el objetivo de comprender qué características están más relacionadas con el abandono estudiantil, se analizaron distintas variables académicas, económicas y personales. Para cada una de ellas se planteó una hipótesis inicial y luego se contrastó con los datos mediante visualizaciones.

##### 4.4.1. Análisis de las Variables de Ingreso

Como se observa en la Figura 3, la mayoría de los ingresantes tienen entre 18 y 22 años, presentan calificaciones medias en la educación secundaria (aproximadamente entre 120 y 140 puntos) y, además, eligieron la carrera como su primera opción al momento de postularse.

Estos resultados sugieren que el estudiante típico llega a la universidad a una edad temprana, con un rendimiento académico previo intermedio y un elevado nivel de motivación inicial, reflejado en la elección prioritaria de la carrera.




Figura 3: Distribución de las variables de ingreso a la universidad.

#### 4.4.2. ¿Aprobar pocas materias en el arranque es sinónimo de abandono?

Hipótesis: *Los estudiantes con menor cantidad de materias aprobadas en primer año tienen mayor probabilidad de abandono.*




Figura 4: Relación entre el rendimiento académico del primer semestre y el estado final del estudiante.

Como se observa en la Figura 4, los datos respaldan la hipótesis planteada. Los estudiantes que abandonaron la carrera tuvieron un rendimiento mucho más bajo durante el primer semestre que aquellos que lograron graduarse.

En general, los alumnos que se graduaron aprobaron alrededor de 6 materias y obtuvieron mejores calificaciones, mientras que los estudiantes en situación de abandono aprobaron pocas materias, e incluso muchos no lograron aprobar ninguna.

Esto sugiere que el desempeño académico durante los primeros meses de la carrera es un fuerte indicador del futuro del estudiante, ya que quienes comienzan con dificultades tienen una mayor probabilidad de abandonar sus estudios.

#### 4.4.3. ¿Las variables económicas impactan en la permanencia?

Hipótesis: "Tener beca reduce la deserción, las crisis económicas la aumentan y el estado de pago de matrícula es altamente predictivo."




Figura 5: Relación entre variables económicas y el estado final del estudiante.

Como se observa en la Figura 5, la situación económica parece tener una influencia importante en la permanencia de los estudiantes.

Los alumnos que mantienen la matrícula al día presentan una mayor proporción de graduados, mientras que aquellos con problemas de pago muestran tasas de abandono considerablemente más altas. De manera similar, los estudiantes becados tienden a graduarse con mayor frecuencia y presentan menores niveles de deserción.

Por otro lado, la presencia de deudas está asociada con una mayor proporción de estudiantes que abandonan sus estudios. Estos resultados sugieren que las dificultades económicas pueden convertirse en un obstáculo para la continuidad académica.

En conjunto, la evidencia respalda la hipótesis planteada: contar con apoyo económico favorece la permanencia, mientras que los problemas financieros aumentan el riesgo de abandono universitario.

#### 4.4.4. El Entorno Familiar: Educación y Ocupación de los Padres

Hipótesis: Los estudiantes cuyos padres poseen niveles educativos más altos presentan mayores tasas de graduación y menores tasas de abandono.




Figura 6: Correlación entre el Entorno Familiar y el Abandono.

A diferencia de lo esperado en la hipótesis inicial, el análisis de correlación demuestra que el entorno familiar (educación y ocupación de los padres) no tiene un impacto sobre el abandono escolar.

#### 4.5. Visualización de agrupamientos con t-SNE

Para validar si nuestro dataset es apto para predecir la deserción, aplicamos t-SNE, una técnica que reduce las más de 30 dimensiones de los estudiantes a un plano 2D en base a sus similitudes.




Figura 7: Visualización bidimensional del perfil de los estudiantes mediante t-SNE.

Como se observa en la Figura 7, la proyección mediante t-SNE revela agrupamientos relativamente definidos entre estudiantes graduados (*Graduate*) y estudiantes que abandonaron (*Dropout*). Esta separación indica que las variables analizadas capturan patrones relevantes relacionados con la trayectoria académica y sugiere que contienen información suficiente para construir modelos predictivos de abandono estudiantil.

#### Conclusiones del Análisis Exploratorio de Datos (EDA)

En resumen, el análisis exploratorio mostró que el rendimiento académico durante los primeros semestres es uno de los factores más importantes para explicar el abandono universitario. Los estudiantes que aprueban más materias y obtienen mejores calificaciones tienen mayores probabilidades de graduarse.

Además, las variables económicas también parecen influir en la permanencia, ya que los estudiantes becados presentan menores niveles de abandono, mientras que los problemas financieros se asocian con una mayor deserción.

Por último, la visualización mediante t-SNE permitió observar agrupamientos entre estudiantes graduados y desertores, lo que indica que las variables analizadas contienen información relevante para distinguir ambos grupos.

Estos resultados sugieren que el problema puede abordarse mediante técnicas de aprendizaje automático para identificar tempranamente a los estudiantes con riesgo de abandono.

## 5. Machine Learning

### 5.1. Definición del Problema

El objetivo de este trabajo es predecir la trayectoria académica de los estudiantes utilizando información personal, académica y socioeconómica.

Se trata de un problema de **clasificación multiclase**.

Para resolver este problema se entrenaron distintos modelos de aprendizaje automático con el fin de identificar patrones que permitan predecir el estado final de cada estudiante. Se prestó especial atención a la detección de alumnos en riesgo de abandono, ya que esto podría ayudar a implementar medidas de apoyo de manera temprana.

El desempeño de los modelos se evaluó utilizando métricas como Recall, F1-Score y matrices de confusión.

### 5.2. Preparación de los Datos

Antes de entrenar los modelos, fue necesario preparar el conjunto de datos para garantizar un proceso de aprendizaje adecuado.

En primer lugar, se separó la variable objetivo del resto de las variables predictoras. Las variables predictoras contienen información académica, demográfica y socioeconómica de los estudiantes, mientras que la variable objetivo representa el estado final del estudiante, pudiendo tomar los valores *Dropout*, *Graduate* o *Enrolled*.

Posteriormente, los datos fueron divididos en conjuntos de entrenamiento y prueba. Se utilizó una partición del 80 % para entrenamiento y 20 % para prueba.

Además, se realizó una división estratificada para mantener la proporción de las clases en ambos conjuntos, evitando que alguna categoría quedara subrepresentada.

```
1 X_train, X_test, y_train, y_test = train_test_split(  
2 X, y,  
3 test_size=0.2,  
4 random_state=42,  
5 stratify=y  
6 )
```

### 5.3. Escalado de Variables

Dado que las variables del conjunto de datos se encuentran en diferentes escalas, se aplicó un proceso de estandarización utilizando **StandardScaler**. Este método transforma cada variable para que tenga media cero y desviación estándar uno.

El escalado resulta especialmente importante para algoritmos sensibles a la magnitud de las variables, como Regresión Logística, K-Nearest Neighbors y Máquinas de Soporte Vectorial, ya que evita que las variables con valores más grandes tengan una influencia desproporcionada durante el entrenamiento.

De esta manera, los datos quedaron adecuadamente preparados para el entrenamiento de los distintos modelos de clasificación, permitiendo realizar una comparación más justa de su desempeño y capacidad predictiva.



## 5.4. Entrenamiento de los Modelos

### 5.4.1. Naive Bayes

Naive Bayes es un algoritmo probabilístico basado en el teorema de Bayes que asume independencia entre las variables predictoras. A pesar de esta simplificación, suele ofrecer buenos resultados en problemas de clasificación y constituye una referencia útil para comparar el desempeño de modelos más complejos.

Cuadro 1: Resumen del Reporte de Clasificación (Naive Bayes)

| Clase                              | Precisión | Recall      | F1-Score |
|------------------------------------|-----------|-------------|----------|
| 0 (Dropout)                        | 72 %      | 67 %        | 69 %     |
| 1 (Enrolled)                       | 27 %      | 18 %        | 22 %     |
| 2 (Graduate)                       | 70 %      | 83 %        | 76 %     |
| <b>Precisión Global (Accuracy)</b> |           | <b>66 %</b> |          |

Como se explicó anteriormente, la métrica más importante para este trabajo es el Recall de la clase *Dropout*, ya que el objetivo principal es identificar estudiantes en riesgo de abandono.

En general, Naive Bayes ofrece resultados aceptables para detectar casos de abandono.

### 5.4.2. KNN (K-Nearest Neighbors)

Con el objetivo de mejorar los resultados obtenidos con Naive Bayes, se entrenó un modelo KNN. Para seleccionar el mejor valor de (K), se utilizó *GridSearchCV* con validación cruzada de 5 particiones, priorizando el *F1-Score* de la clase *Dropout*. Como resultado, se obtuvo una configuración óptima de **13 vecinos**.

Cuadro 2: Resumen del Reporte de Clasificación (KNN Optimizado)

| Clase                              | Precisión | Recall      | F1-Score |
|------------------------------------|-----------|-------------|----------|
| 0 (Dropout)                        | 78 %      | 64 %        | 70 %     |
| 1 (Enrolled)                       | 42 %      | 18 %        | 25 %     |
| 2 (Graduate)                       | 69 %      | 92 %        | 79 %     |
| <b>Precisión Global (Accuracy)</b> |           | <b>70 %</b> |          |

Los resultados muestran una mejora respecto al modelo anterior. Para la clase *Dropout*, el modelo logra identificar de manera más confiable a los estudiantes en riesgo de abandono.

En general, KNN obtuvo un mejor desempeño que Naive Bayes, tanto en términos de exactitud global como en la identificación de estudiantes con riesgo de abandono.

### 5.4.3. Regresión Logística

Los resultados obtenidos muestran que este fue el modelo con mejor desempeño entre los algoritmos evaluados.

Para la clase *Dropout*, el modelo logró identificar correctamente una gran proporción de estudiantes en riesgo de abandono, manteniendo una baja cantidad de falsas alarmas.

Estos resultados posicionan a la Regresión Logística como el modelo más adecuado para este problema.

Cuadro 3: Resumen del Reporte de Clasificación (Regresión Logística)

| Clase                              | Precisión   | Recall | F1-Score |
|------------------------------------|-------------|--------|----------|
| 0 (Dropout)                        | 82 %        | 76 %   | 79 %     |
| 1 (Enrolled)                       | 51 %        | 25 %   | 33 %     |
| 2 (Graduate)                       | 77 %        | 95 %   | 85 %     |
| <b>Precisión Global (Accuracy)</b> | <b>76 %</b> |        |          |

#### 5.4.4. Máquinas de Soporte Vectorial (SVM)

Para este modelo se realizó una búsqueda de hiperparámetros mediante *GridSearchCV*, obteniéndose como mejor configuración un kernel RBF con  $C = 10$  y  $\gamma = 0.01$ .

Los resultados obtenidos muestran una exactitud global del **75 %**, ubicándose por encima de Naive Bayes y KNN. Para la clase *Dropout*, el modelo alcanzó demostrando una buena capacidad para identificar estudiantes en riesgo de abandono.

En general, SVM mostró un desempeño sólido en las tres clases. Sin embargo, la Regresión Logística obtuvo mejores resultados en la detección de estudiantes en riesgo de abandono, por lo que fue seleccionada como modelo final.

Cuadro 4: Resumen del Reporte de Clasificación (SVM Optimizado)

| Clase                              | Precisión   | Recall | F1-Score |
|------------------------------------|-------------|--------|----------|
| 0 (Dropout)                        | 79 %        | 73 %   | 76 %     |
| 1 (Enrolled)                       | 49 %        | 38 %   | 43 %     |
| 2 (Graduate)                       | 79 %        | 89 %   | 84 %     |
| <b>Precisión Global (Accuracy)</b> | <b>75 %</b> |        |          |

#### 5.4.5. Árbol de Decisión

También se entrenó un Árbol de Decisión optimizado mediante *GridSearchCV* con validación cruzada. La mejor configuración encontrada utilizó el criterio de impureza Gini, una profundidad máxima de 5 niveles y un valor de `min_samples_split` igual a 2.

Sin embargo, esta mejora se vio acompañada por una disminución en el rendimiento global respecto de modelos como SVM y Regresión Logística.

Cuadro 5: Resumen del Reporte de Clasificación (Árbol de Decisión Optimizado)

| Clase                              | Precisión   | Recall | F1-Score |
|------------------------------------|-------------|--------|----------|
| 0 (Dropout)                        | 84 %        | 61 %   | 70 %     |
| 1 (Enrolled)                       | 38 %        | 60 %   | 46 %     |
| 2 (Graduate)                       | 81 %        | 79 %   | 80 %     |
| <b>Precisión Global (Accuracy)</b> | <b>69 %</b> |        |          |

#### 5.4.6. Random Forest

Cuadro 6: Resumen del Reporte de Clasificación (Random Forest Final)

| Clase                              | Precisión   | Recall | F1-Score |
|------------------------------------|-------------|--------|----------|
| 0 (Dropout)                        | 83 %        | 75 %   | 79 %     |
| 1 (Enrolled)                       | 53 %        | 35 %   | 42 %     |
| 2 (Graduate)                       | 78 %        | 93 %   | 85 %     |
| <b>Precisión Global (Accuracy)</b> | <b>77 %</b> |        |          |

#### 5.4.7. Evaluación Gráfica: Curvas ROC y Precision-Recall

Para complementar la evaluación de los modelos, se analizaron las curvas ROC y Precision-Recall. Dado que el objetivo principal del trabajo es identificar estudiantes en riesgo de abandono, se prestó especial atención a las métricas *Recall* y *F1-Score* para la clase *Dropout*.

Debido al desbalance presente en los datos, la evaluación de los modelos se centró principalmente en las métricas *Recall* y *F1-Score* para la clase *Dropout*, ya que el objetivo principal del trabajo es identificar estudiantes en riesgo de abandono.




Figura 8: Curvas ROC - Cuervas PR

Al analizar la Figura 8, se observa que los mejores resultados fueron obtenidos por la Regresión Logística y Random Forest. Ambos modelos presentan una buena capacidad para distinguir entre las distintas categorías de estudiantes.

Sin embargo, al centrarnos en la detección de estudiantes en riesgo de abandono, la Regresión Logística obtuvo el mejor desempeño general. Esto indica que logra un mejor equilibrio entre identificar correctamente los casos de deserción y mantener una cantidad reducida de falsas alarmas.

## 6. Conclusiones

En este trabajo se desarrollaron y compararon distintos modelos de aprendizaje automático para predecir la trayectoria académica de estudiantes universitarios, clasificándolos como *Graduate*, *Dropout* o *Enrolled*.

A partir del análisis exploratorio se observó que las variables académicas, especialmente aquellas relacionadas con el desempeño durante el primer año, son las que presentan una mayor relación con el estado final del estudiante. En particular, la cantidad de materias aprobadas y las calificaciones obtenidas durante el primer semestre resultaron ser indicadores clave para identificar situaciones de riesgo de abandono.

Debido al desbalance presente en los datos, la evaluación de los modelos se centró principalmente en las métricas *Recall* y *F1-Score* para la clase *Dropout*, ya que el principal objetivo era detectar estudiantes con riesgo de deserción.

Se evaluaron distintos algoritmos de clasificación, entre ellos Naive Bayes, KNN, Árboles de Decisión, Random Forest, SVM y Regresión Logística. Los resultados mostraron que la Regresión Logística obtuvo el mejor desempeño general, logrando un buen equilibrio entre la detección de estudiantes en riesgo de abandono y la reducción de falsas alarmas.

En conclusión, los resultados obtenidos demuestran que las técnicas de aprendizaje automático pueden constituir una herramienta útil para la identificación temprana de estudiantes con riesgo de deserción. Esto podría permitir a las instituciones educativas implementar estrategias de acompañamiento e intervención más oportunas, contribuyendo a mejorar la permanencia y el éxito académico de los estudiantes.